

Fashion-MNIST CNN Architecture 이해 및 최적화 보고서

팀 정보

항목	내용
조원	김선정, 임유리, 이민형
실습명	CNN Architecture 이해 및 최적화

목차

1. 실습 목적
2. 데이터셋과 Baseline 구조
3. 개인별 개선 아이디어와 가설
4. 실험 설계와 공통 조건
5. 실험 1 결과와 해석
6. 실험 2: Dropout 비율 비교
7. 실험의 한계와 추가 확인 사항
8. 최종 결론


1. 실습 목적

Fashion-MNIST 분류용 Vanilla CNN을 Baseline으로 정하고 과적합을 줄일 방법을 실험했다. 정확도가 가장 높은 조합을 바로 찾기보다는 Epoch, Learning Rate, Dropout을 하나씩 바꿔 보면서 각각의 변경이 Loss와 Accuracy에 어떤 차이를 만드는지 살펴봤다.


2. 데이터셋과 Baseline 구조

Fashion-MNIST는 10종류의 의류가 담긴 28×28 흑백 이미지 데이터셋이다. 원본 Train 데이터 60,000개 중 54,000개는 학습에, 6,000개는 Validation에 사용했다. Test 데이터 10,000개는 마지막 성능 확인에만 사용했다.

Label: Ankle boot



Label: Pullover




입력 텐서의 형태는 $[B, 1, 28, 28]$ 이다. B 는 한 번에 모델에 넣는 이미지 수이고, 1 은 흑백 채널을 뜻한다. 마지막 두 값은 이미지의 높이와 너비다.

$[B, 1, 28, 28]$	
→ Conv1 + ReLU	$[B, 32, 28, 28]$
→ MaxPool	$[B, 32, 14, 14]$
→ Conv2 + ReLU	$[B, 64, 14, 14]$
→ MaxPool	$[B, 64, 7, 7]$
→ Flatten	$[B, 3136]$
→ FC1 + ReLU	$[B, 128]$
→ FC2	$[B, 10]$

Baseline에는 Adam Optimizer, Learning Rate 0.001 , Batch Size 32 , 10 epoch를 적용했다. Dropout, BatchNorm, Early Stopping은 사용하지 않았고 모든 학습은 MPS에서 실행했다.

Baseline의 Validation Accuracy는 0.9257 , Test Accuracy는 0.9185 였다. Validation Loss는 4 epoch에서 0.2211 로 가장 낮았지만 10 epoch에는 0.2912 까지 높아졌다. 같은 시점의 Train Accuracy는 0.9877 이었다. 하지만, 학습을 계속할수록 Train 데이터에는 더 잘 맞지만 Validation 데이터에서는 손실이 커지는 모습을 보였다.



3. 개인별 개선 아이디어와 가설

실험 전에 정한 질문은 다음과 같다.

- 학습을 일찍 끝내면 후반부의 과적합을 줄일 수 있을까?
- Learning Rate를 낮추면 Validation Loss가 더 안정적으로 내려갈까?
- Dropout을 적용하면 Train과 Validation 성능 차이가 줄어들까?

김선정: Epoch 4

Baseline의 Validation Loss는 4 epoch에서 가장 낮고 이후 다시 높아졌다. 학습을 4 epoch에서 끝내면 불필요한 후반 학습을 피할 수 있고, Final Validation Loss와 Train-Validation Accuracy Gap도 줄어들 것으로 예상했다.

임유리: Learning Rate 0.0005

Learning Rate가 크면 한 번에 갱신되는 가중치의 폭도 커져 손실이 낮은 지점을 지나칠 수 있다고 생각했다. 값을 **0.001** → **0.0005**로 낮추면 더 작은 폭으로 학습하면서 Best Validation Loss가 내려가고 Validation 또는 Test Accuracy도 좋아질 것으로 예상했다.

이민형: Dropout 0.2

Baseline은 Train Accuracy와 Validation Accuracy의 차이가 컸고 학습 후반의 Validation Loss도 높아졌다. **FC1** → **ReLU** 뒤에 Dropout 0.2를 넣으면 Train Loss는 다소 높아지더라도 특정 뉴런에 지나치게 의존하는 현상이 줄어 Validation Loss와 Accuracy Gap이 작아질 것으로 예상했다.

4. 실험 설계와 공통 조건

무엇 때문에 결과가 달라졌는지 구분할 수 있도록 각 실험에서는 가설과 관련된 요소 하나만 바꿨다.

구분	Epoch	Learning Rate	Dropout	변경 요소
Baseline	10	0.0010	0.0	없음
김선정 가설 실험	4	0.0010	0.0	Epoch
임유리 가설 실험	10	0.0005	0.0	Learning Rate
이민형 가설 실험	10	0.0010	0.2	Dropout


데이터 분할, Batch Size 32, Adam, CrossEntropyLoss, CNN 크기, seed 42, MPS 실행 조건은 모두 같게 두었다. 모델을 비교할 때는 Test Accuracy가 아니라 Validation Accuracy와 Validation Loss를 우선 기준으로 삼았다. 테스트를 평가지표로써 학습을 하면, 최종적으로 봐야하는 것을 학습하는 것이기에, 실제로 모델의 일반화 성능을 확인할 수 있는 Validation loss와 Validation accuracy를 보는 것이 맞다고 생각했다.

진행 항목	담당
실험 1 타이핑	김선정
실험 2 타이핑	임유리
가설과 결과 해석	팀원 전원


5. 실험 1 결과와 해석

실험	Train Acc	Valid Acc	Test Acc	Train-Valid Gap	Final Train Loss	Final Valid Loss	Best Valid Loss	Best Epoch
Baseline	0.9877	0.9257	0.9185	0.0621	0.0628	0.2912	0.2211	4
김선정, Epoch 4	0.9445	0.9200	0.9136	0.0245	0.1837	0.2211	0.2211	4
임유리, LR 0.0005	0.9719	0.9273	0.9216	0.0445	0.1080	0.2188	0.2055	8
이민형, Dropout 0.2	0.9715	0.9242	0.9185	0.0473	0.1088	0.2443	0.2142	6

Fashion-MNIST Hypothesis Trends | Device: MPS



Fashion-MNIST Hypothesis Results | Device: MPS



김선정 팀원의 실험에서는 Final Validation Loss가 $0.2912 \rightarrow 0.2211$ 로 낮아졌고 Train-Validation Accuracy Gap도 $0.0621 \rightarrow 0.0245$ 로 줄었다. 예상한 대로 후반부 과적합은 줄었지만 Test Accuracy는 0.9136 으로 Baseline보다 낮았다. 4 epoch 종료가 과적합 완화에 도움이 되었지만 분류 정확도까지 높이지는 못했다.

임유리 팀원의 실험에서는 Best Validation Loss는 0.2055 로 Baseline의 0.2211 보다 낮았다. Validation Accuracy는 0.9273 , Test Accuracy는 0.9216 으로 세 개인 실험 가운데 가장 높았다. Learning Rate를 줄였을 때 손실이 내려갈 것이라는 예상과 맞는 결과였다.

이민형 팀원의 실험에서는 Final Train Loss가 $0.0628 \rightarrow 0.1088$ 로 높아진 반면 Final Validation Loss는 $0.2912 \rightarrow 0.2443$, Gap은 $0.0621 \rightarrow 0.0473$ 으로 낮아졌다. Dropout이 학습 데이터에 과하게 맞는 현상을 줄이는 방향은 확인했지만 Test Accuracy는 Baseline과 같은 0.9185 였다. 이번 설정에서는 정확도 상승보다 과적합 완화 쪽의 변화가 더 뚜렷했다.

다만 실험의 목적은 가장 높은 Test accuracy를 얻는 것이 아니라, 과적합 문제를 해결하는 것이다. Epoch를 4로 줄인 실험에서 Accuracy Gap이 가장 크게 감소했지만, 이는 학습 자체를 조기에 종료한 결과이다. 반면 Dropout은 동일한 10 epoch 학습 조건에서도 과적합을 완화하는 방향을 보였다. 따라서 규제 강도에 따른 변화를 추가로 확인하기 위해 Dropout 비율을 세분화하여 비교하였다.

[실험 후 추가한 가설]

- Dropout을 0.1부터 0.5까지 바꾸면 어느 구간에서 균형이 가장 좋을까?


6. 실험 2: Dropout 비율 비교

실험 1에서 Dropout 0.2가 Accuracy Gap을 줄이는 방향을 보였다. 두 번째 실험에서는 나머지 조건을 고정하고 Dropout 만 0.1, 0.2, 0.3, 0.4, 0.5로 바꿨다.


실험 전에는 Dropout이 높아질수록 Train Accuracy와 Accuracy Gap이 낮아지지만, 값이 너무 커지면 학습에 필요한 특징까지 빠져 Validation Accuracy가 다시 낮아질 것으로 예상했다.

Dropout	Train Acc	Valid Acc	Test Acc	Train-Valid Gap	Final Train Loss	Final Valid Loss	Best Valid Loss	Best Epoch
0.0	0.9877	0.9257	0.9185	0.0621	0.0628	0.2912	0.2211	4
0.1	0.9818	0.9228	0.9177	0.0589	0.0881	0.2667	0.2127	7
0.2	0.9715	0.9242	0.9185	0.0473	0.1088	0.2443	0.2142	6
0.3	0.9686	0.9237	0.9187	0.0450	0.1322	0.2362	0.2095	7
0.4	0.9694	0.9275	0.9198	0.0419	0.1446	0.2171	0.2052	8
0.5	0.9603	0.9238	0.9210	0.0364	0.1715	0.2265	0.2134	8

Fashion-MNIST Dropout Sweep | Device: MPS



Validation Loss by Epoch and Dropout | Device: MPS



Dropout을 0.0 → 0.5로 높이는 동안 Train Accuracy는 0.9877 → 0.9603, Train-Validation Accuracy Gap은 0.0621 → 0.0364로 낮아졌다. Dropout 비율이 커질수록 학습 데이터에 과적합 정도가 줄어드는 흐름이 나타났다.

Validation Accuracy는 Dropout 0.4에서 0.9275로 가장 높았고, Best Validation Loss도 0.2052로 가장 낮았다. Dropout 0.5의 Test Accuracy가 0.9210으로 더 높기는 했지만 Test 결과를 보고 설정을 고르면 모델 선택에 Test 데이터가 개입하게 된다. 그래서 Validation 결과가 가장 좋았던 Dropout 0.4를 우선 후보로 정했다.


Dropout을 높인다고 Accuracy가 계속 오르지 않는 것이다. 과적합을 줄이는 효과와 학습에 사용할 정보가 줄어드는 효과가 함께 나타났고, 이번에 비교한 범위에서는 0.4가 두 효과 사이에서 가장 나은 균형을 보였다.

7. 실험의 한계와 추가 확인 사항


실험을 진행하면서 가장 먼저 눈에 띈 한계는 입력 이미지가 28×28 크기의 흑백 이미지라는 점이었다. 이번에 실험한 Epoch, Learning Rate, Dropout 범위에서는 Validation Accuracy 개선 폭이 제한적이었다. 따라서 우리는 모델의 아키텍처나 하이퍼파라미터 문제보다는 원본 이미지에서 확인할 수 있는 형태나 질감 같은 제품 특징이 정확히 드러나지 않는 영향이 더 클 것으로 생각했다. 예를 들어보자면, Shirt, T-shirt/top, Coat처럼 윤곽이 비슷한 옷은 작은 흑백 이미지에서 구분하기 더 어려울 가능성이 있다.

다만 현재 표에는 전체 정확도만 있으므로 이 추측을 결과처럼 단정할 수는 없다. 클래스별 정확도와 실제 오분류 이미지를 확인해야 어떤 클래스끼리 자주 혼동했는지 말할 수 있을 것으로 예상된다. 그래서 Confusion Matrix를 다음 실험에서 확인해 볼 수 있을 것 같다.

Correct
Actual: Ankle boot
Predicted: Ankle boot



Wrong
Actual: Ankle boot
Predicted: Sandal



8. 최종 결론

Epoch, Learning Rate, Dropout을 하나씩 바꿔 보니 각 변경이 만드는 차이가 서로 달랐다. Epoch를 4로 줄인 실험은 Accuracy Gap을 가장 많이 줄였지만 Test Accuracy도 함께 낮아졌다. Learning Rate 0.0005는 개인별 실험 중 Best Validation Loss가 가장 낮았고 Validation Accuracy와 Test Accuracy도 가장 높았다. Dropout은 비율이 높아질수록 Accuracy Gap을 줄였지만 정확도가 같은 방향으로 계속 높아지지는 않았다.

Dropout 비교에서는 0.4가 Validation Accuracy 0.9275, Best Validation Loss 0.2052로 가장 좋은 Validation 결과를 보였다. 따라서 최종 후보의 Dropout은 0.4로 정했다. Learning Rate 0.0005 실험과의 차이가 크지 않고 두 결과 모두 단일 seed(random_seed = 42)에서 나온 값이므로, 현재 수치만으로 어느 모델이 항상 더 좋다고 판단할 수는 없다.

다만 데이터의 해상도가 너무 작았기에, 다양한 기법을 통해서 과적합을 방지하려는 시도가 잘 적용되지 않았다. 추가적인 데이터 증강 기법이나 다른 기법을 찾아서 과적합을 줄이는 시도를 해보려 한다.

최종 후보 구조

```
Conv1 → ReLU → Pool  
→ Conv2 → ReLU → Pool  
→ Flatten → FC1 → ReLU → Dropout(0.4) → FC2
```

항목	최종 후보
Epoch	10
Learning Rate	0.001
Dropout	0.4
Validation Accuracy	0.9275
Test Accuracy	0.9198
Best Validation Loss	0.2052