

EDA Findings

조원 : P229-이지원, P213-김선정, P209-곽민규, P231-임유리, P240-현용찬

1. 데이터 구조에서 확인한 특징

- **Finding:** 데이터는 2,930개 행과 15개 열로 구성되며, Target은 주택 판매가격인 SalePrice이다.
- **Evidence:** 변수는 Target을 포함한 수치형 변수 11개와 범주형 변수 4개로 구성되어 있다. Overall_Qual, Overall_Cond는 정수형이지만 실제로는 1~10의 등급을 나타내는 서열형 변수이다.
- **Possible Action:** 등급형 변수는 단순 연속형 변수와 구분하여 처리한다. Year_Built, Garage_Yr_Blt는 분석 시 연도 자체보다 주택 및 차고의 연식으로 변환하는 방안도 고려한다.

2. 결측치가 있는 변수와 가능한 의미

- **Finding:** 결측치는 주로 차고 건축연도인 Garage_Yr_Blt에서 발견되며, 단순 누락보다 차고가 없다는 의미일 가능성이 크다.
- **Evidence:** Garage_Yr_Blt에는 159건(5.4%), Total_Bsmt_SF와 Garage_Cars에는 각각 1건의 결측치가 있다. Garage_Yr_Blt가 결측인 159건 중 157건은 Garage_Cars가 0이므로 대부분 차고가 없는 주택으로 해석할 수 있다.
- **Possible Action:** 차고가 없는 주택은 Garage_Yr_Blt를 임의의 평균값으로 대체하기보다 '차고 없음'을 나타내는 별도 지표를 생성한다. 나머지 소수 결측치는 원자료를 확인한 뒤 중앙값 대체 등의 방법을 적용한다.

3. Target 분포의 특징과 고려할 변환

- **Finding:** SalePrice는 고가 주택에 의해 오른쪽 꼬리가 길어진 양의 왜도 분포를 보인다.
- **Evidence:** 평균 가격은 약 \$180,796으로 중앙값 \$160,000보다 높으며, 최솟값은 \$12,789, 최댓값은 \$755,000이다. 왜도는 1.74로 나타났다.
- **Possible Action:** 회귀분석에서 잔차의 안정성과 정규성을 개선하기 위해 $\log_{1p}(\text{SalePrice})$ 와 같은 로그 변환을 고려한다. 변환 전후의 분포와 모델 성능을 비교하여 최종 적용 여부를 결정한다.

4. 이상치 후보와 처리 전 확인 사항

- **Finding:** Overall_Cond, SalePrice, Lot_Area, Total_Bsmt_SF, Gr_Liv_Area 등에서 IQR 기준 이상치 후보가 확인되었다.
- **Evidence:** 이상치 후보는 Overall_Cond 252건, SalePrice 137건, Lot_Area 127건, Total_Bsmt_SF 123건, Gr_Liv_Area 75건이다. 특히 Lot_Area의 최댓값은 215,245, Gr_Liv_Area의 최댓값은 5,642로 일반적인 값보다 매우 크다. Garage_Yr_Blt의 최댓값 2207은 입력 오류 가능성이 있다.

- **Possible Action:** 이상치라는 이유만으로 제거하지 않고 실제 대형 주택인지, 입력 오류인지 먼저 확인한다. 등급형 변수인 Overall_Cond에는 일반 연속형 변수와 동일한 이상치 기준을 기계적으로 적용하지 않는다.

5. 주택가격과 관계가 강한 수치형 변수

- **Finding:** 주택의 전반적인 품질과 주거 면적이 판매가격과 가장 강한 양의 관계를 보인다.
- **Evidence:** SalePrice와의 Pearson 상관계수는 Overall_Qual 0.80, Gr_Liv_Area 0.71, Garage_Cars 0.65, Total_Bsmt_SF 0.63, Year_Built 0.56 순으로 높게 나타났다.
- **Possible Action:** 이 변수들을 주요 설명변수로 우선 활용한다. 다만 상관관계가 인과관계를 의미하지 않으며, 면적·차고·건축연도 변수 사이의 다중공선성도 추가로 확인한다.

6. 가격 차이가 뚜렷한 범주형 변수

- **Finding:** Kitchen_Qual, Exter_Qual, Neighborhood에 따라 주택가격 차이가 뚜렷하게 나타난다.
- **Evidence:** 외관 품질별 중앙가격은 Fa \$85,000, TA \$139,000, Gd \$219,500, Ex \$370,967이다. 주방 품질도 TA \$136,500에서 Ex \$325,624로 높아진다. 지역별 중앙가격은 MeadowV \$88,250에서 StoneBr \$319,000까지 차이가 난다.
- **Possible Action:** Kitchen_Qual과 Exter_Qual은 품질 순서를 반영한 서열형 인코딩을 고려한다. Neighborhood와 House_Style은 명목형 변수이므로 원-핫 인코딩을 적용하고, 표본 수가 매우 적은 범주는 통합 여부를 검토한다.

7. 향후 전처리 단계에서 수행할 작업

- **Finding :** 변수별 의미와 분포가 다르므로 모든 변수에 동일한 전처리를 적용하는 것은 적절하지 않다.
- **Evidence:** Lot_Area의 왜도는 12.82로 매우 크지만, 등급형 변수와 연도 변수는 서로 다른 의미와 범위를 가진다. 또한 차고 관련 결측치는 시설 부재를 의미할 가능성이 높다.
- **Possible Action:** 다음 전처리를 수행한다.

차고 관련 결측치의 의미를 반영하여 ‘차고 없음’ 변수를 생성한다.

소수의 단순 결측치는 수치형 변수의 중앙값 등으로 대체한다.

Garage_Yr_Blt의 2207과 같은 입력 오류 후보를 확인하고 수정한다.

SalePrice, Lot_Area, Gr_Liv_Area 등 오른쪽 왜도가 큰 변수의 로그 변환을 검토한다.

극단값을 실제 관측값과 오류로 구분한 뒤 제거·상한 조정 여부를 결정한다.

품질 변수에는 서열형 인코딩, 지역과 주택 형태에는 원-핫 인코딩을 적용한다.

스케일에 민감한 모델을 사용할 경우 수치형 변수 표준화를 진행한다.

Insight & Issue

Ames Housing 데이터에서는 주택의 전반적인 품질, 주거 면적, 차고 규모, 지하 면적이 판매가격과 강한 관계를 보였다. 주방·외관 품질과 지역에 따라서도 가격 차이가 뚜렷했다. 모델링 전에는 결측치의 의미를 반영하고, 입력 오류와 실제 극단값을 구분하며, 왜도가 큰 변수의 변환과 범주형 변수 인코딩을 수행해야 한다.