

Feature Engineering

팀원 : P229-이지원, P213-김선정, P209-곽민규, P231-임유리, P240-현용찬

실험 1. 결측치 처리와 이상치 완화

1. 무엇을 바꾸었나요?

- `Garage\_Yr\_Blt`, `Total\_Bsmt\_SF`, `Garage\_Cars`의 결측치를 Train 데이터의 중앙값으로 대체했습니다. `Gr\_Liv\_Area`, `Lot\_Area`의 IQR 이상치는 행을 삭제하지 않고 경계값으로 clipping했습니다.

2. 어떤 변화를 기대했나요?

- 결측치 때문에 모델이 학습하지 못하는 문제를 없애고, 일부 매우 큰 주택·대지 값이 선형회귀 계수를 과도하게 좌우하는 현상을 줄이고자 했습니다.

3. 실제로 어떤 현상이 나타났나요?

- 결측치는 Train/Test 모두 0개가 되었고, 학습 행은 삭제하지 않았습니다. 학습 데이터에서 `Gr\_Liv\_Area` 이상치 59건, `Lot\_Area` 이상치 113건을 경계값으로 제한했습니다.

4. 무엇을 알 수 있었나요?

- 이 데이터의 결측치는 단순 오류라기보다 차고나 지하실이 없는 주택을 나타낼 가능성이 있으므로, 다음 실험에서는 0 대체나 시설 유무 파생변수도 비교할 필요가 있습니다.

실험 2. 파생변수 생성

1. 무엇을 바꾸었나요?

- ``Total_Area = Gr_Liv_Area + Total_Bsmt_SF``와 ``Quality_Area = Overall_Qual * Gr_Liv_Area``를 추가했습니다.

2. 어떤 변화를 기대했나요?

- 지상 면적만 사용하는 것보다 지하실을 포함한 전체 사용 면적을 반영하고, 같은 면적이라도 품질이 높은 주택의 가격이 더 높다는 관계를 모델에 전달하고자 했습니다.

3. 실제로 어떤 현상이 나타났나요?

- 변수 수가 14개에서 16개로 늘었고, 범주형 인코딩까지 적용한 최종 변수 수는 53개가 되었습니다. 기존 모델 대비 MAE는 23,759달러에서 16,172달러로, RMSE는 38,577달러에서 27,787달러로 감소했습니다. Adjusted R²는 0.81에서 0.89로 상승했습니다.

4. 무엇을 알 수 있었나요?

- Ames 주택 가격은 단순한 방 개수보다 면적과 전체 품질의 결합 효과를 반영할 때 더 잘 설명되었습니다. 다만 로그변환 후 ``Total_Bsmt_SF`` 왜도가 1.34에서 -5.08로 바뀌어, 변환을 일괄 적용하기보다 변수별 분포를 확인해 선택해야 합니다.

Insight

결측치가 있는 `Garage_Yr_Blt`, `Total_Bsmt_SF`, `Garage_Cars`는 중앙값으로 대체하고, `Gr_Liv_Area`와 `Lot_Area`의 이상치는 **IQR** 기준으로 **clipping**하였습니다. 또한 지상 면적과 지하실 면적을 합한 `Total_Area`, 주택 품질과 지상 면적을 곱한 `Quality_Area` 파생변수를 추가하였습니다. 면적 변수에는 로그변환을 적용하여 분포의 치우침을 완화하고자 하였습니다.

결측치 처리, 이상치 완화, 면적·품질 파생변수, 범주형 인코딩, 로그변환을 적용한 모델이 기존 모델보다 모든 주요 지표에서 개선되었습니다. 단, 동일한 **Test** 분할에서 얻은 결과이므로 일반화 성능을 확정하기보다는 교차검증과 전처리 조합별 추가 비교가 필요합니다.

1. `Total_Area` 파생변수

```
X_train_step3["Total_Area"] = (  
    X_train_step3["Gr_Liv_Area"]  
    + X_train_step3["Total_Bsmt_SF"]  
)
```

-> 지상 생활면적과 지하실 면적을 더해 주택의 전체 사용 면적을 만들었습니다.

2. `Quality_Area` 파생변수

```
X_train_step3["Quality_Area"] = (  
    X_train_step3["Overall_Qual"]  
    * X_train_step3["Gr_Liv_Area"]  
)
```

-> 주택 품질 등급과 지상 생활면적을 곱해, 넓고 품질이 좋은 집의 특성을 함께 반영했습니다. `Train`과 `Test` 데이터 모두 같은 방식으로 계산했습니다.

3. 결측치 처리

```
numeric_missing_settings = {  
    "Garage_Yr_Blt": "median",  
    "Total_Bsmt_SF": "median",  
    "Garage_Cars": "median"  
}
```

-> 결측치를 학습 데이터의 중앙값으로 대체했습니다.

4. 이상치 처리

```
outlier_settings = {  
    "Gr_Liv_Area": "clip",  
    "Lot_Area": "clip"  
}
```

-> 지상 생활면적과 대지면적의 극단값을 IQR 기준 경계 안으로 제한했습니다.

5. 로그변환

```
log_settings = {  
    "Lot_Area": "log1p",  
    "Gr_Liv_Area": "log1p",  
    "Total_Bsmt_SF": "log1p"  
}
```

-> 면적 변수의 치우친 분포를 완화하기 위해 log1p 변환을 적용했습니다.